Análisis y pronóstico del desempeño de ventas en una cadena de supermercados

Cynthia Michelle Santos
Carné: 20230493

José Antonio Valdés
Carné: 20230050

Juan Diego Letona
Carné: 20230285

***Resumen*—Este trabajo analiza el desempeño comercial de una cadena de supermercados y evalúa alternativas para anticipar la venta diaria de sus vendedores. Se estudiaron siete tablas del proyecto, con 6,758,125 registros originales de ventas y 23 vendedores. Después de excluir 67,526 ventas sin fecha, se analizaron 6,690,599 transacciones entre el 1 de enero y el 9 de mayo de 2018. Se combinaron análisis descriptivo, pruebas estadísticas y modelos predictivos, mediante un proceso organizado en Kedro. Ridge y LightGBM se compararon con cuatro reglas simples, reservando los últimos 28 días para evaluación temporal. LightGBM obtuvo el menor error absoluto medio, de Q 32,276.89 por vendedor y día, pero su mejora de 0.10 % frente al promedio histórico no alcanzó el umbral de adopción de 2 %. Se recomienda el promedio histórico, cuyo error porcentual medio fue de 2.24 %. Las ventas fueron estables y las diferencias entre vendedores se asociaron principalmente con el valor promedio de sus transacciones. Se proponen metas apoyadas en el historial, pruebas controladas de descuentos y capacitación comercial. Las oportunidades monetarias se presentan como escenarios sujetos a supuestos, sin atribuirles un efecto causal demostrado.**

***Palabras clave*—desempeño comercial, pronóstico de ventas, validación temporal, líneas base, interpretación de modelos, decisiones de negocio.**

I. Introduction

La información de ventas puede ayudar a una empresa a definir metas, distribuir esfuerzos de capacitación y revisar promociones. Sin embargo, disponer de millones de registros no garantiza que un modelo complejo permita tomar mejores decisiones. Primero es necesario entender qué mide cada registro, corregir problemas de calidad y comparar cualquier modelo con alternativas fáciles de explicar.

Este proyecto aborda el Reto 1, *Desempeño de las ventas*, del curso Machine Learning for Business. Su alcance comprende la generación de ingresos, las tendencias, la contribución del personal y la evidencia que podría orientar la contratación. El trabajo integra los cuadernos de introducción, exploración y resultados, los seis procesos del código, sus configuraciones, las pruebas y el resumen de resultados del repositorio [1].

El aporte consiste en conectar el análisis con una decisión concreta: determinar si un modelo de aprendizaje automático aporta una mejora suficiente para justificar su implementación. En paralelo, se identifican oportunidades comerciales que pueden evaluarse mediante intervenciones posteriores. El texto explica los conceptos técnicos al introducirlos para que la gerencia y otros lectores sin formación especializada puedan interpretar sus implicaciones.

II. Business problem

A. Contexto y responsables de la decisión

La gerencia comercial necesita conocer cuánto podría vender cada persona por día y si las diferencias de desempeño justifican metas o incentivos distintos. Recursos Humanos requiere evidencia para orientar la capacitación y definir competencias al contratar. También interesa revisar si los descuentos se relacionan con un mayor volumen de compra.

La pregunta central es: *£cuánto venderá cada vendedor por día y qué factores de su historial y perfil se relacionan con su desempeño?* Como preguntas complementarias se examina si las ventas crecen, cuánto contribuye cada vendedor y qué comportamientos comerciales conviene probar o reforzar.

B. Objetivo y criterio de éxito

El objetivo analítico es estimar el ingreso neto diario de cada vendedor. Se trata de una tarea de *regresión*: predecir una cantidad monetaria, en lugar de asignar una etiqueta. La unidad de evaluación es el par vendedor–día.

La métrica principal es el error absoluto medio, o MAE, que expresa cuánto se aleja el pronóstico de la venta real, en promedio y sin considerar el signo del error. Se complementa con una medida porcentual para facilitar su interpretación. La regla de negocio exige que un modelo de aprendizaje automático reduzca el MAE de la mejor regla simple al menos un 2 %. Este umbral es un criterio operativo del proyecto; no representa por sí mismo una prueba de rentabilidad ni de significancia estadística.

III. Data

A. Origen, estructura y cobertura

Los datos proceden del material proporcionado para el curso y están organizados en siete tablas relacionadas mediante identificadores. La Tabla I resume sus dimensiones originales, documentadas en los cuadernos. No se dispone de una identificación verificable de la empresa ni de una descripción completa del procedimiento de recolección.

Cada fila de ventas vincula un vendedor, un cliente y un producto. Los identificadores de venta y los números de transacción son únicos según la exploración, por lo que no se dispone de una canasta con varias líneas que permita estudiar compras conjuntas. Los 23 vendedores, los 452 productos y los 98,759 clientes aparecen en las ventas originales. No se observaron relaciones sin correspondencia entre las tablas.

TABLA I
TABLAS ORIGINALES DEL CONJUNTO DE DATOS

Tabla	Filas	Campos	Función principal
`sales`	6,758,125	9	Venta, vendedor, cliente, producto y fecha.
`products`	452	9	Precio y atributos del producto.
`categories`	11	2	Clasificación del producto.
`employees`	23	8	Identidad y perfil del vendedor.
`customers`	98,759	6	Identidad y ciudad del cliente.
`cities`	96	4	Ubicación y relación con país.
`countries`	206	3	Catálogo de países.

Todas las ciudades están asociadas con un único país en estos datos, por lo que el catálogo de 206 países no equivale a una cobertura comercial internacional.

La información con fecha cubre 129 días consecutivos, del 1 de enero al 9 de mayo de 2018. Para mantener la convención monetaria del proyecto, se utiliza el símbolo Q. El esquema de los archivos no documenta explícitamente la moneda; por tanto, esta notación no verifica que los importes correspondan a operaciones reales en quetzales.

B. Calidad y preparación

La columna `TotalPrice` contiene cero en todas las ventas. Por ello, se elimina y se reconstruye el ingreso a partir del precio del producto, la cantidad y el descuento:

$$R_i = P_i\, q_i\, (1 - d_i), \tag{1}$$

donde R_i es el ingreso neto de la venta i, P_i el precio unitario, q_i la cantidad y d_i el descuento expresado como proporción. El ingreso bruto es $P_i q_i$ y el monto descontado es $P_i q_i d_i$. Se supone que el precio del catálogo es aplicable a la fecha de la venta, pues no existe un historial de precios.

Se excluyeron 67,526 ventas sin fecha, aproximadamente el 1 % del total, porque no pueden asignarse a un día. Quedaron 6,690,599 registros. Cada vendedor perdió entre 0.95 % y 1.05 % de sus ventas por esta causa. Aunque el contraste de proporcionalidad detectó diferencias ($p = 0.009$), su magnitud fue pequeña; esto reduce la preocupación por un desequilibrio grande, pero no demuestra ausencia de sesgo.

No se observaron duplicados. El proceso conserva controles para eliminarlos si aparecen y verifica que productos, clientes y vendedores existan. Valida cantidades entre 1 y 1000 y descuentos de 0 %, 10 % o 20 %; las cantidades efectivamente observadas fueron de 1 a 25. Los registros de alto ingreso se conservaron porque corresponden a combinaciones válidas de precio y cantidad. La regla del rango intercuartílico marcó 0.73 % de las transacciones como atípicas, sin evidencia suficiente para tratarlas como errores.

La inicial del segundo nombre falta en 977 clientes, pero no interviene en el análisis. El código de país "NA" se conserva como texto para evitar que sea interpretado como un valor ausente. Atributos de producto como "Unknown" se documentan y no se utilizan como predictores en este reto.

C. Transformación para el modelado

Las ventas se agregan por vendedor y fecha, sumando ingreso, operaciones y unidades. El *ticket promedio* se define como ingreso neto dividido entre número de transacciones; representa el valor medio de una venta. Se construye una cuadrícula de 23 vendedores por 129 días: 2,967 observaciones. El código completa con cero los días sin registros para conservar intervalos diarios regulares, una decisión que requiere distinguir ausencia de ventas y ausencia de datos al aplicarse en producción.

El modelo utiliza 24 variables: cinco de calendario; tres ingresos rezagados a 1, 7 y 14 días; seis medias y desviaciones móviles en ventanas de 7, 14 y 28 días; un promedio histórico acumulado; seis indicadores recientes de volumen, ticket y descuentos; y tres de perfil: edad, antigüedad y edad al contratar. Estas últimas se calculan con fecha de referencia del 10 de mayo de 2018. El identificador del vendedor y la fecha se excluyen como entradas directas. El género se utiliza únicamente para una comparación descriptiva y se excluye de los modelos predictivos.

IV. METHODS

A. Análisis descriptivo y estadístico

La exploración revisa faltantes, duplicados, consistencia entre tablas, distribuciones y valores atípicos. Las tendencias se comparan mediante promedios diarios y semanas completas. Esto evita interpretar el total de mayo, que contiene solo nueve días, como una caída frente a meses completos.

Se aplica ANOVA para comparar promedios de ventas, ticket y unidades entre grupos. Se utiliza la correlación de Spearman para estudiar asociaciones entre variables sin exigir una relación lineal, y la prueba de Mann–Whitney para comparar ingresos por género. El nivel de referencia es $\alpha = 0.05$. Un valor p pequeño indica evidencia contra la hipótesis de igualdad o de ausencia de asociación bajo los supuestos del contraste; no mide el tamaño ni la importancia comercial de una diferencia. Un valor mayor a 0.05 tampoco demuestra igualdad.

La autocorrelación describe cuánto se parece la venta de un día a la de días anteriores. Su revisión permite valorar si copiar el dato de ayer o de la semana pasada podría ser una buena regla de pronóstico.

B. Reglas simples y modelos candidatos

Se comparan cuatro líneas base, entendidas como reglas de referencia: vender lo mismo que ayer; vender lo mismo que el mismo día de la semana anterior; utilizar el promedio de los 28 días previos; y utilizar el promedio de todos los días anteriores del mismo vendedor. Esta última se expresa como:

$$\widehat{y}_{s,t} = \frac{1}{t-1} \sum_{u=1}^{t-1} y_{s,u}, \tag{2}$$

TABLA II
SEPARACIÓN TEMPORAL PARA EL MODELADO

Etapa	Días	Filas	Fechas de 2018
Historia inicial	28	644	1–28 de enero
Entrenamiento	73	1,679	29 de enero–11 de abril
Prueba	28	644	12 de abril–9 de mayo

donde s identifica al vendedor y t al día dentro de su historia disponible. Cada nueva observación actualiza el promedio para el pronóstico del día siguiente.

Ridge es una regresión lineal que limita el tamaño de sus coeficientes para reducir ajustes excesivos al ruido [2]. Las variables se estandarizan dentro de un proceso que aprende sus transformaciones solo con el conjunto de entrenamiento correspondiente.

LightGBM combina árboles de decisión construidos de forma secuencial. Cada árbol busca corregir errores del conjunto anterior, lo que permite representar relaciones no lineales e interacciones entre variables [3]. Se incluye como alternativa más flexible a Ridge, sin asumir de antemano que esa flexibilidad mejorará los resultados.

C. Validación temporal y control de información

Las variables históricas se calculan usando únicamente días anteriores, con un desplazamiento de un día antes de construir los promedios. El número de ventas, el ticket y los descuentos del propio día se eliminan como entradas porque solo se conocen al cierre. Así se evita que el modelo use información que todavía no estaría disponible al emitir el pronóstico.

La ventana de 28 días exige descartar las primeras 28 fechas por vendedor como filas de modelado, aunque esos días sí alimentan su historial. De las 2,967 observaciones se conservan 2,323: 1,679 para entrenamiento y 644 para prueba. Estos tamaños y fechas se derivan de la cobertura y de las reglas del código (Tabla II).

Dentro del entrenamiento se emplean cuatro divisiones de validación temporal por fechas completas mediante `TimeSeriesSplit` [4]. Cada división aprende del pasado y valida con fechas posteriores, manteniendo juntos los vendedores de un mismo día. Optuna explora 40 configuraciones por modelo y minimiza el MAE promedio de las cuatro divisiones; la semilla aleatoria es 42 [5]. Los modelos finales se ajustan con todo el entrenamiento.

La prueba simula una secuencia de pronósticos *a un día*: al predecir una fecha se permite utilizar las ventas reales ya observadas de fechas anteriores, incluso dentro de los 28 días de prueba. Los parámetros de Ridge y LightGBM permanecen fijos. Por tanto, el resultado no equivale a pronosticar los 28 días de una sola vez desde el 11 de abril.

D. Métricas e interpretación del modelo

Para N observaciones, el error absoluto medio es:

$$\mathrm{MAE} = \frac{1}{N}\sum_{i=1}^{N} |y_i - \widehat{y}_i|. \tag{3}$$

El RMSE eleva al cuadrado las diferencias antes de promediarlas y obtener su raíz; por ello penaliza más los errores grandes. El MAPE promedia el error absoluto como porcentaje del valor real. El coeficiente R^2 compara el error cuadrático con el de predecir una media global: cerca de cero indica poca capacidad para explicar las fluctuaciones, y un valor negativo indica un desempeño inferior a esa referencia en error cuadrático. Estas métricas se calculan sobre observaciones vendedor–día, no sobre el total diario de la cadena.

SHAP se aplica a LightGBM para estimar cuánto contribuye cada variable a sus predicciones [6]. La importancia global se resume mediante el promedio de las contribuciones en valor absoluto. Este procedimiento explica el comportamiento del modelo; no demuestra que modificar una variable produzca un cambio causal en las ventas.

E. Organización y reproducibilidad

Kedro organiza el trabajo en seis procesos: limpieza, construcción de variables, entrenamiento, evaluación, análisis comercial y escenarios de impacto [7]. Un catálogo centraliza las entradas y salidas y los archivos de parámetros documentan las decisiones. Las pruebas del repositorio revisan, entre otros aspectos, limpieza, orden temporal y selección del modelo. La integración continua está configurada para ejecutar estilo, pruebas y el proceso completo con una muestra aleatoria de 0.5 % de las ventas. Esta muestra sirve para validar el funcionamiento del software y no para sustituir las métricas del conjunto completo.

V. MODEL SELECTION

La selección se rige por la siguiente mejora relativa:

$$\Delta = 100\left(1 - \frac{\mathrm{MAE}_{\mathrm{ML}}}{\mathrm{MAE}_{\mathrm{base}}}\right). \tag{4}$$

Solo se adopta aprendizaje automático si $\Delta \geq 2\,\%$. En las validaciones internas, el mejor MAE fue Q 34,273.24 para Ridge y Q 34,196.75 para LightGBM. Estos errores corresponden a periodos distintos del bloque final de prueba y no deben confundirse con sus resultados.

Los hiperparámetros son controles definidos antes de ajustar el modelo. Para Ridge, Optuna seleccionó una regularización $\alpha = 1678.5982$. Para LightGBM, eligió 131 árboles, tasa de aprendizaje 0.01715, 11 hojas, mínimo de 99 observaciones por hoja, fracción de filas 0.72118, fracción de variables 0.57088 y regularización L2 de 0.86381. La configuración favorece árboles relativamente contenidos y aprendizaje gradual.

En la prueba, LightGBM redujo el MAE de la mejor línea base en aproximadamente Q 33.64 por vendedor y día: de Q 32,310.53 a Q 32,276.89. La mejora relativa fue 0.1041 %, que se redondea a 0.10 %. Para alcanzar el umbral de 2 %, el

MAE tendría que ser como máximo Q 31,664.32. Se selecciona, por tanto, el *promedio histórico del vendedor*. Además de su simplicidad operativa, obtuvo un RMSE menor y un R^2 mayor que LightGBM en este bloque de prueba.

VI. Results

A. Comparación predictiva

La Tabla III recoge las métricas almacenadas en el cuaderno de resultados. Las cantidades monetarias se redondean a dos decimales y el MAPE a cuatro para distinguir diferencias pequeñas.

El promedio histórico disminuye el MAE en 28.6 % frente a copiar la venta de ayer. Su MAPE es aproximadamente 2.24 %, frente a 3.13 % de esa regla ingenua. El MAE no constituye un límite máximo del error individual ni garantiza que cada vendedor tenga exactamente el mismo desempeño predictivo.

El R^2 cercano a cero no contradice el MAPE bajo. Las ventas se mantienen cerca de un nivel estable y predecir ese nivel genera errores pequeños en relación con el ingreso, aunque el modelo apenas anticipe las fluctuaciones alrededor del promedio. Por ejemplo, si una venta diaria fuese de Q 1,450,000, un error de Q 32,310.53 representaría alrededor de 2.23 %; este ejemplo ilustra la escala y no es una observación adicional del conjunto.

B. Ventas, tendencia y contribución del equipo

El ingreso neto reconstruido fue Q 4,289,241,827.19, equivalente a Q 33,249,936.64 por día para toda la cadena. La variación relativa diaria del total, medida como desviación estándar dividida entre promedio, fue 0.55 %. A nivel vendedor–día, la variación fue aproximadamente 2.8 %.

Las 18 semanas completas mostraron una pendiente de apenas 0.008 % de su ingreso semanal medio por semana. La comparación entre días de la semana produjo $p = 0.8674$, sin evidencia de diferencias sistemáticas en esta muestra. El promedio de autocorrelaciones de los vendedores, revisado entre 1 y 14 días de rezago, tuvo un máximo absoluto de 0.044. Esto es consistente con una señal temporal débil para los modelos considerados.

Cada vendedor aportó entre 4.298 % y 4.387 % del ingreso total. La brecha acumulada entre el mayor y el menor ingreso fue 2.07 %. Devon Brewer encabezó el ingreso total, con aproximadamente Q 188.17 millones y una participación de 4.387 %. Shelby Riddle obtuvo el mayor ticket entre los extremos descritos en la exploración; liderar ingreso y liderar ticket son criterios distintos.

Con las bandas operativas de ± 0.5 % frente al ingreso medio del equipo, 18 vendedores quedaron en el promedio, tres por encima y dos por debajo. Catorce mostraron pendiente semanal positiva y nueve negativa; estos conteos no incluyen una prueba de significancia de cada pendiente y no justifican, por sí solos, afirmar que alguien mejoró o empeoró de forma sostenida.

El contraste entre vendedores detectó diferencias en ingreso diario ($p \approx 1.79 \times 10^{-7}$) y ticket diario ($p \approx 2.27 \times 10^{-18}$), pero no en número diario de transacciones ($p = 0.3957$). El ingreso acumulado se asoció más con el ticket promedio (Spearman $\rho = 0.906$) que con el número de ventas ($\rho = 0.238$). Los vendedores de mejor ticket tendieron a vender más unidades en transacciones de productos de mayor precio ($\rho \approx 0.90$ en la exploración). Son asociaciones descriptivas; parte de la relación entre ticket e ingreso es inherente a cómo se construyen estas medidas.

C. Descuentos y perfil del vendedor

Los descuentos sumaron Q 132,468,072.83, equivalentes al 3.00 % del ingreso bruto reconstruido. Se aplicaron a 19.99 % de las transacciones. La Tabla IV muestra que las unidades por operación fueron similares en los tres grupos.

ANOVA produjo $p = 0.0631$ para unidades por nivel de descuento. No se detectó una diferencia al nivel de 5 %, pero esto no demuestra que los descuentos carezcan de efecto sobre demanda, retención o frecuencia de compra. Las transacciones observadas no revelan cuántas compras se habrían perdido sin una promoción.

Para el perfil, las correlaciones con ingreso fueron: edad $\rho = 0.176$, $p = 0.4221$; antigüedad $\rho = -0.305$, $p = 0.1570$; y edad al contratar $\rho = 0.309$, $p = 0.1510$. La comparación por género dio $p = 0.3246$. No se encontró evidencia estadística suficiente de asociación con estas variables en los 23 vendedores. La ausencia de detección debe interpretarse considerando el tamaño reducido de la muestra.

D. Interpretación de LightGBM con SHAP

La Fig. 1 reproduce la figura exportada por el proyecto. La variable con mayor importancia fue el promedio histórico de ingreso del vendedor (10.56 % de la magnitud SHAP total), seguida del ticket medio de siete días (8.20 %), la proporción de transacciones con descuento del día anterior (7.76 %), su media de siete días (7.19 %) y el ingreso de 14 días antes (6.15 %). La antigüedad representó 3.82 %.

Estos porcentajes describen cómo LightGBM distribuye la magnitud de sus explicaciones entre variables. No son porcentajes de ingreso ni de variación estadística explicada. Que una variable aparezca entre las más importantes tampoco implica que el modelo tenga gran capacidad predictiva. El análisis SHAP se refiere al candidato LightGBM; el método finalmente recomendado es la media histórica, cuya regla se explica directamente con la ecuación (2).

VII. Business interpretation

A. Metas y gestión del desempeño

La estabilidad de las ventas permite utilizar el promedio individual como punto de referencia transparente para planificar. El error de 2.24 % es una medida media de precisión, no una tolerancia contractual ni un intervalo de confianza. Una meta comercial también debe considerar capacidad, turnos y oportunidades de venta, variables ausentes del conjunto.

La mejora de 0.10 % de LightGBM es insuficiente según el criterio acordado. Adoptar la media histórica reduce la carga de explicar, actualizar y supervisar una solución más compleja, aunque los costos concretos de implementación

TABLA III
RESULTADOS EN LOS ÚLTIMOS 28 DÍAS: 644 OBSERVACIONES VENDEDOR–DÍA

Método	Tipo	MAE (Q)	RMSE (Q)	MAPE (%)	R^2
LightGBM	Aprendizaje automático	32,276.89	40,468.67	2.2341	0.0051
Promedio histórico del vendedor	**Línea base seleccionada**	**32,310.53**	**40,249.85**	**2.2351**	**0.0158**
Ridge	Aprendizaje automático	32,416.81	40,317.55	2.2454	0.0125
Promedio móvil de 28 días	Línea base	32,789.00	40,866.30	2.2679	−0.0146
Mismo día de la semana pasada	Línea base	44,616.40	56,162.49	3.0880	−0.9162
Ayer	Línea base	45,253.13	56,127.81	3.1290	−0.9139

TABLA IV
RESULTADOS OBSERVADOS POR NIVEL DE DESCUENTO

Descuento	Transacciones	Unidades/venta	Ingreso/venta (Q)
0 %	5,353,035	13.002	660.88
10 %	670,318	13.023	595.21
20 %	667,246	13.000	528.36

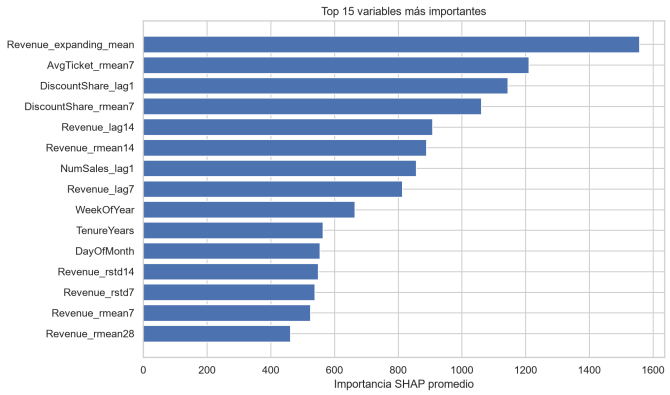


Fig. 1. Importancia media absoluta SHAP de las 15 variables principales de LightGBM. Fuente: figura original de `02_resultados.ipynb`.

no fueron cuantificados. Las diferencias pequeñas entre vendedores aconsejan prudencia al convertir clasificaciones en incentivos o decisiones de personal.

El ticket y la asignación de unidades a productos de mayor precio ofrecen una hipótesis de capacitación. Sin embargo, un ticket más alto podría reflejar oportunidades asignadas o tipos de cliente, además de habilidad. El análisis no permite separar estas explicaciones. Para contratación, la evidencia favorece evaluar competencias observables mediante ejercicios de atención y venta, sin derivar filtros demográficos de las asociaciones estudiadas.

B. Escenarios monetarios condicionados

El módulo de impacto calcula cuánto ingreso adicional resultaría bajo supuestos específicos. La Tabla V presenta los escenarios del proyecto, expresados en millones de Q. Las reducciones de descuentos son alternativas entre sí y no deben sumarse.

En descuentos, se multiplica el monto observado por la fracción que se dejaría de otorgar. Por ejemplo, reducirlo 25 % arroja Q 33,117,018.21 durante los 129 días. Esto supone que se conserva el mismo número de transacciones, cantidades y mezcla de productos. Reducir 25 % del *monto* descontado no significa disminuir todos los descuentos en 25 puntos porcentuales.

TABLA V
ESCENARIOS DE INGRESO ADICIONAL, NO BENEFICIOS DEMOSTRADOS

Escenario	129 días	Anualizado	Aumento (%)
Reducir 25 % del monto de descuentos	33.12	93.70	0.77
Reducir 50 % del monto de descuentos	66.23	187.41	1.54
Reducir 100 % del monto de descuentos	132.47	374.81	3.09
Venta sugestiva hasta la mediana	7.92	22.40	0.18

En venta sugestiva se consideran productos cuyo precio supera Q 75.25, umbral correspondiente al percentil 75 del precio en las transacciones. Once vendedores quedaron por debajo de la mediana del equipo, de aproximadamente 13.010 unidades por venta de mayor valor. Para ellos se calcula la brecha hasta esa meta, multiplicada por sus operaciones de alto valor y por su ingreso neto por unidad. El resultado es Q 7,918,241.72 de ingreso adicional hipotético en el periodo. Supone que las unidades adicionales no sustituyen otras compras y que existe demanda y disponibilidad para venderlas.

La anualización multiplica cada escenario por $365/129$. Es una extrapolación mecánica que no estima estacionalidad ni comprueba que las condiciones se mantengan durante un año. Ninguno de estos importes equivale a utilidad neta: faltan costos de producto, ejecución, capacitación y posibles cambios en comportamiento. Tampoco se ha estimado la interacción entre descuentos y venta sugestiva, por lo que no corresponde sumar sus resultados como beneficio conjunto validado.

VIII. RECOMMENDATIONS

A. Implementar una referencia diaria comprensible

Usar el promedio histórico de cada vendedor como pronóstico de referencia y actualizarlo después de cada cierre con ventas reales disponibles. Mostrar a gerencia el pronóstico, la venta real, la desviación y el error acumulado. Para una persona nueva sin historial, utilizar provisionalmente una referencia del equipo y evaluar su desempeño por separado; esta solución

de arranque es una recomendación adicional y no fue probada por el proyecto.

Revisar MAE, MAPE y sesgo por vendedor y para la cadena. El sesgo puede medirse con el promedio de venta real menos pronóstico: un valor persistentemente positivo señalaría subestimación. Si aparecen días con venta cero, complementar o sustituir MAPE, que se vuelve inestable. Como propuesta operativa, realizar seguimiento semanal y una revisión mensual de cambios en nivel de ventas.

B. Probar cambios en descuentos antes de ampliarlos

Asignar una prueba controlada, idealmente aleatoria, a grupos comparables de clientes, productos o periodos para evaluar una reducción moderada de descuentos frente a la política vigente. Medir unidades, transacciones, ingreso neto, margen bruto y recompra. Definir duración y tamaño de muestra antes de iniciar según el efecto mínimo comercialmente relevante.

La gerencia comercial debería aprobar una ampliación solo si el piloto muestra una mejora compatible con la experiencia del cliente y el margen. Los escenarios de Q 33.12 a Q 132.47 millones en el periodo son referencias para formular hipótesis; no constituyen compromisos de ahorro ni justifican eliminar todas las promociones de inmediato.

C. Capacitar y evaluar competencias comerciales

Diseñar un piloto de venta sugestiva que compare formación y práctica guiada con la operación habitual. Priorizar el aprendizaje del equipo y utilizar como referencia inicial la mediana de unidades por operación de mayor valor. Supervisar ticket, unidades, margen y satisfacción, ajustando por oportunidades atendidas para evitar incentivos a vender productos inadecuados.

Recursos Humanos puede incorporar simulaciones de asesoría, conocimiento de productos y comunicación orientada a necesidades del cliente. El estudio no sustenta requisitos de edad, antigüedad o género para predecir éxito. Cualquier criterio de selección derivado de competencias debe validarse con resultados posteriores, pues no se dispone de un experimento de contratación.

D. Mejorar datos y reevaluar los modelos

Recopilar al menos un ciclo anual completo e incorporar turnos y horas trabajadas, tienda, afluencia, inventario, promociones, feriados, costos y precios históricos. Estas variables permitirían distinguir capacidad y oportunidades de desempeño individual y evaluar rentabilidad.

Después de ampliar los datos, repetir la comparación temporal, reservar un nuevo periodo independiente y conservar el umbral de mejora de 2 % como regla explícita, revisándolo a la luz de costos reales. Una adopción futura debería acompañarse de evidencia de estabilidad entre periodos y vendedores, y de beneficio operativo medido.

IX. Limitations

A. Representatividad y horizonte

Los precios poco plausibles, las distribuciones casi uniformes y la homogeneidad entre vendedores sugieren que el conjunto podría ser simulado. Es una inferencia de la exploración, no una procedencia confirmada. La ausencia de identificación de la empresa, moneda explícita e historial de precios limita su interpretación económica. La cobertura de 129 días de 2018 no permite estudiar estacionalidad anual ni extrapolar directamente a condiciones actuales.

Aunque existen millones de transacciones, solo hay 23 personas para estudiar perfiles y 129 fechas para estudiar dinámica temporal. El volumen transaccional no elimina estas limitaciones. Descartar fechas faltantes también puede introducir sesgo si su ausencia depende de factores no observados.

B. Asociación, inferencia y equidad

Las comparaciones son observacionales. No aíslan el efecto de descuentos, capacitación, edad o antigüedad de otros factores. ANOVA y las demás pruebas dependen de supuestos que no se validan exhaustivamente, y múltiples contrastes exploratorios aumentan la posibilidad de detectar alguna diferencia por azar. No se calcularon intervalos de confianza para todos los efectos ni se corrigieron todos los contrastes por comparaciones múltiples.

Las bandas de desempeño son umbrales descriptivos, no categorías con superioridad demostrada. La relación entre ingreso y ticket contiene un componente matemático compartido. Excluir género del modelo no garantiza equidad: edad y variables relacionadas con el historial también requieren revisión antes de usarse para decisiones de personal.

C. Alcance de la evaluación predictiva

El bloque final contiene solo 28 días y se utiliza tanto para comparar candidatos como para aplicar la regla de selección. Los hiperparámetros se ajustan únicamente con entrenamiento, pero la recomendación final debería confirmarse en otro periodo independiente para reducir el sesgo de selección. No se reportan intervalos de incertidumbre del error ni pruebas de significancia de la pequeña diferencia de MAE entre modelos.

La evaluación corresponde a un día de anticipación con actualización del historial. No valida un pronóstico de cuatro semanas emitido de una sola vez. Tampoco demuestra desempeño para vendedores nuevos: excluir el identificador no elimina la necesidad de 28 días previos para construir varias variables. Edad, antigüedad y edad al contratar están relacionadas entre sí, lo que también dificulta separar sus contribuciones.

D. Impacto y reproducibilidad disponible

Los escenarios de ingresos suponen comportamiento estable y no incorporan elasticidad de demanda, sustitución de compras, costos ni estacionalidad. La ausencia de una diferencia significativa en unidades por descuento no prueba que retirarlo mantenga las compras. La anualización agrega un supuesto adicional de estabilidad.

En la copia del repositorio revisada, las tablas completas de `data/01_raw` y las salidas completas de `data/08_reporting` no están incluidas; se conserva una muestra para integración continua. Las cifras de este reporte

proceden de las salidas almacenadas en los cuadernos, de `resultados_resumen.json` y de las figuras, contrastadas con el código y sus parámetros. No se ejecutó nuevamente el entrenamiento sobre las ventas completas para elaborar este documento. La existencia de pruebas y de una configuración de integración continua no equivale a una certificación de ejecución en esta revisión.

X. Conclusion

El proyecto muestra que una solución sencilla puede ser adecuada cuando las ventas se mantienen estables y las variables disponibles ofrecen poca información sobre sus fluctuaciones. El promedio histórico por vendedor obtuvo un MAE de Q 32,310.53 y un MAPE de 2.24 %, y redujo el MAE 28.6 % frente a copiar la venta de ayer. LightGBM logró un MAE apenas 0.10 % menor que esa media, por lo que no cumplió el umbral de adopción de 2 %.

El análisis descriptivo encontró contribuciones similares entre vendedores y una asociación entre ingreso y ticket promedio. No identificó evidencia suficiente para definir un perfil de contratación a partir de edad, antigüedad o género. En descuentos se observaron cantidades por transacción parecidas, lo que justifica estudiar su política mediante pruebas controladas, sin concluir que su eliminación mantendría la demanda.

La decisión recomendada es utilizar el promedio histórico como referencia de planificación, mejorar la información operativa y validar las intervenciones comerciales con pilotos. Los escenarios de ingresos orientan esa evaluación, mientras que sus beneficios reales deben demostrarse con datos adicionales y mediciones de margen, clientes y operación.

References

[1] C. M. Santos, J. A. Valdés y J. D. Letona, "Desempeño de las ventas: Proyecto final ML for Business," 2026. Material consultado: `README.md`, cuadernos `00_intro`, `01_exploracion` y `02_resultados`; código, configuración, pruebas y `resultados_resumen.json`. [En línea]. Disponible: https://github.com/Cynthiss/ML-Proyecto-Final.

[2] Scikit-learn developers, "Ridge," documentación de scikit-learn. [En línea]. Disponible: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Ridge.html. Consultado: 14 nov. 2026.

[3] G. Ke *et al.*, "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," en *Advances in Neural Information Processing Systems*, vol. 30, 2017. [En línea]. Disponible: https://proceedings.neurips.cc/paper_files/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html.

[4] Scikit-learn developers, "TimeSeriesSplit," documentación de scikit-learn. [En línea]. Disponible: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.TimeSeriesSplit.html. Consultado: 14 nov. 2026.

[5] T. Akiba, S. Sano, T. Yanase, T. Ohta y M. Koyama, "Optuna: A Next-generation Hyperparameter Optimization Framework," en *Proc. 25th ACM SIGKDD Int. Conf. Knowledge Discovery & Data Mining*, 2019, pp. 2623–2631, doi: 10.1145/3292500.3330701.

[6] S. M. Lundberg y S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," en *Advances in Neural Information Processing Systems*, vol. 30, 2017. [En línea]. Disponible: https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html.

[7] Kedro contributors, "Kedro documentation." [En línea]. Disponible: https://docs.kedro.org/en/stable/. Consultado: 14 nov. 2026.